今天主要进行的是第二步,第一步是为了将最近的代码工作串起来而写上的

1. 执行程序名为 公司名称识别并建立上下游关系.py 程序,

上面最后一行在读取 global firm names.xlsx 文件,使用时请改成**对应文件保存的位置**

```
global_worksh = global_workbk.sheet_by_name('0x77igavdumz8vul')
global_cpnames = global_worksh.col_values(colx = 7, start_rowx = 1)
global_cpkey = global_worksh.col_values(colx = 0, start_rowx = 1)
# 组成列表
global_namekey = list(zip(global_cpnames, global_cpkey))

us_workbk = xlrd.open_workbook(r'C:\Users\jc\Documents\Pydata'
+'\Database Table\\us names.xlsx')
```

上面最后一行在读取 us_ names.xlsx 文件, 使用时请**改成对应文件保存的位置**

上面最后一行在读取customer.xlsx文件位置,使用时请**改成对应文件保存的位置**

```
customer_worksh = customer_workbk.sheet_by_name('vozkv@ioajsw5wov')
customer_downstream = customer_worksh.col_values(colx = 2, start_rowx = 1)
customer_upkey = customer_worksh.col_values(colx = 0, start_rowx = 1)
```

```
# 组成列表
customer up down = list(zip(customer upkey,customer downstream))
# global firm names 和 us names 的Global Company Key 和 Company Name列表合并后去重
Allnamekey lst = list(set( global namekey+us namekey))
#对customer_up_down列表也去重
customer_up_down = list(set(customer_up_down))
#按照Global Company Key进行排序
Allnamekey_lst.sort(key=lambda x:x[1])
# 将Global Company Key 和 Company Name 写入Allcompany表中
Allcompany = xlwt.Workbook()
Allcompany_sheet = Allcompany.add_sheet('sheet1')
name_list = ['Global Company Key','Company Name(upstream)','Downstream']
for i in name list:
    Allcompany_sheet.write(0, name_list.index(i), i)
for namekey in Allnamekey_lst:
    Allcompany sheet.write(Allnamekey lst.index(namekey)+1,0,namekey[1])
    Allcompany_sheet.write(Allnamekey_lst.index(namekey)+1,1,namekey[0])
cust num = [[i[1],0] for i in Allnamekey lst]
#比较 upstream key(customer_up_down[i][0])和global company key(Allnamekey_lst[j][1])
for upkey_down in customer_up_down:
   for name_key in Allnamekey_lst:
       if upkey_down[0] == name_key[1]:
           Allcompany_sheet.write(Allnamekey_lst.index(name_key)+1
                                  ,2+cust_num[Allnamekey_lst.index(name_key)][1]
                                  ,upkey_down[1])
           cust_num[Allnamekey_lst.index(name_key)][1] += 1
# 保存文件
Allcompany.save('Allcompany.xlsx')
```

最后一行是保存Allcompany.xlsx文件的位置,可以不修改,默认保存在同py文件的文件夹下。

Allcomany.xlsx文件里保存的有

第一列:Global Company Key 每个公司特有的一串数字

第二列: Company Name(upstream) 上游公司的全称

第三列以后: Downstream 与上有公司对应的,下游公司的缩写

对数据进行了哪些处理:

- 1. 里面上游公司的名称没有重复,都只出现一次
- 2. 数据都是按照 Global Company Key 公司特有的关键字 从小到大排列

在我的电脑上代码执行大约需要25min

执行后结果如下:

4 A	В	C	D	E
Global Company Key	Company Name(upstream)	Downstream		
001004	AAR CORP	U.S. Government	Not Reported	North America
001013	ADC TELECOMMUNICATIONS INC			
001019	AFA PROTECTIVE SYSTEMS INC	Not Reported		
001045	AMERICAN AIRLINES GROUP INC			
001050	CECO ENVIRONMENTAL CORP	Foreign		
001062	ASA GOLD AND PRECIOUS METALS			
001072	AVX CORP	Not Reported	Electronic Distributors	
001075	PINNACLE WEST CAPITAL CORP	Wholesale energy sales	Transmission services for others	Retail residential electric service
001076	PROG HOLDINGS INC	Home Exercise and Home Improvement	Other	Furniture and Mattresses
001078	ABBOTT LABORATORIES	International	Other Emerging Markets	United States
001082	SERVIDYNE INC			
001084	WORLDS INC			
001094	ACETO CORP	McKesson Corp	Europe	AmerisourceBergen Corp
001096	MORGUARD CORP			
001097	ACMAT CORP -CL A			
001104	ACME UNITED CORP	E-commerce	International	Not Reported
001117	BK TECHNOLOGIES CORP	Public Safety	Business and Industrial	Industrial
001119	ADAMS DIVERSIFIED EQUITY FD			
001121	ADAMS RESOURCES & ENERGY INC	Not Reported		
001161	ADVANCED MICRO DEVICES	Sony Corp	HEWLETT-PACKARD CO	Not Reported
001166	ASM INTERNATIONAL NV	7 Customers	China	Taiwan
001173	AEROSONIC CORP			
001177	AETNA INC	U.S. Federal Government	Medicaid	Foreign
001186	AGNICO EAGLE MINES LTD	4 Customers	Not Reported	The state of the s
001209	AIR PRODUCTS & CHEMICALS INC	Sale of equipment	Merchant	Outside the United States
001210	AIR T INC	International	Federal Express Corp	United States
001224	SPIRE ALABAMA INC	Residential	Commercial and Industrial	Other Customer
001225	ALABAMA POWER CO	Wholesale	Residential-Retail	Other
001228	ALANCO TECHNOLOGIES INC	3 Customers		
001230	ALASKA AIR GROUP INC	Direct to customer	Reservation Call Centers	Traditional Agencies
001234	ATRION CORP	Not Reported	Outside the United States	-

2. 对获取到的全称进行预处理:

执行公司全名的预处理.py文件

从第一步中得到的Allcompany.xlsx中获取所有公司的Allcpkey(每个公司特有的一串数字)和Allcpname(公司全名)

注:第一行路径对应上面第一部分代码中生成的Allcompany文件位置

```
从Allcompany中读取数据
Allcpkey 用于保存公司缩写
Allcpname用于保存公司全称
....
Allcompany = xlrd.open_workbook(r'C:\Users\jc\Documents\大学'
+'\\0大三其他\\_金融数据挖掘科研课题'
+'\Allcompany.xlsx')
Allcompany_sheet = Allcompany.sheet_by_name('sheet1')
```

```
Allcpkey = Allcompany_sheet.col_values(colx = 0, start_rowx = 1)
Allcpname = Allcompany_sheet.col_values(colx = 1, start_rowx = 1)
```

创建表Allcpdata,全称All Company Data表格,用于存储全称公司的:

Global Company key, Full name, company type, country, Cleande Full Name

其中 Cleande Full Name 表示去除了公司后缀的全称,用于后续与缩写的匹配 country 用于存储公司可能所在的国家,有些无法识别出就空着

1. 创建All company match表格的表头

```
# 1.创建All Company Data表格,写好表头
Allcpdata_wb = xlwt.Workbook()
Allcpdata = Allcpdata_wb.add_sheet('sheet1')
name_list = ['Global Company key', 'Full name', 'company type', 'country', 'Cleaned Full Name']

for i in range(len(name_list)):
    Allcpdata.write(0, i , name_list[i])
```

2. 将Global Company key写进表中 第i+1行,第0列

```
for i in range(len(Allcpkey)):
    Allcpdata.write(i+1, 0 , Allcpkey[i])
```

3. 将Full name写进表中 第i+1行,第1列

```
for i in range(len(Allcpname)):
    Allcpdata.write(i+1, 1, Allcpname[i])
```

4. 将company type写入表中第i+1行,第2列,用 cleanco中typesources()和match()判断

```
for i in range(len(Allcpname)):
    Allcpdata.write(i+1, 2, matches(Allcpname[i], typesources()))
```

5. 将country 写入表中 第i+1行,第3列, 用cleanco中match()和countrysources()判断

```
for i in range(len(Allcpname)):
    Allcpdata.write(i+1, 3,matches(Allcpname[i],countrysources()))
```

6. 清理不必要的后缀与符号,并转换为小写字符写入表中,第i+1行,第4列,用clean_name()判断。

```
for i in range(len(Allcpname)):
    Allcpdata.write(i+1, 4, (clean_name(Allcpname[i]).lower()))
```

关于 clean_name 方法解释如下:

- 1. 用cleanco中的basename删除后缀 (A.S./ N.V./ SA/SG S.A.与这一步共同进行单独处理) (-CL A,-CL B,-CL C,-CL I)单独处理
- 2. 删除未识别出的后缀 ETF, A/S, -ADR, INC-OLD, group,
- 3. 再用cleanno中的basename删除一次,确保删除干净了

以下是clean_name方法,**基本能将company name中所有后缀与国家名都删除,并不丢失此外的 其他字符。**

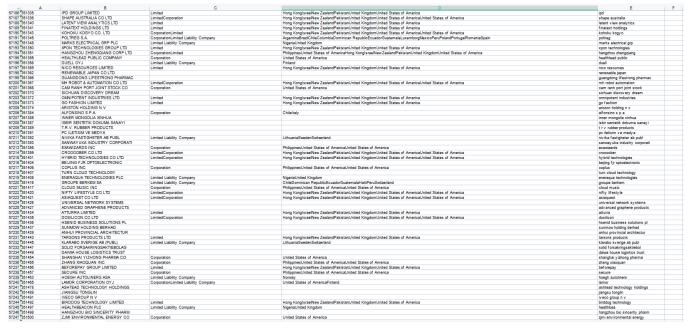
```
def clean name(string):
   1. 用cleanco中的basename删除后缀
   (A.S./ N.V./ SA/SG S.A.与这一步共同进行单独处理)
   (-CL A,-CL B,-CL C ,-CL I)单独处理
   2.删除未识别出的后缀
   ETF , A/S , -ADR , INC-OLD, group,
   3. 再用cleanno中的basename删除一次,确保删除干净了
   return 公司清理后缀后的名称
   1 1 1
   #1.
   # 截取最后5个判断是否有-CL ?类后缀,如果有则删去
   str_suffix0 = string[:len(string)-6:-1][::-1].replace(' ','')
   if '-CL' in str suffix0:
      string = string[:string.find('-')]
   string = re.sub(r'[\W]',' ',string) # 首先删去字符影响,替换为空格
   string = cleanco.basename(string) # 用cleanco里自带的basename做第一次后缀清除
```

```
clean_suffix0 = ['A/S','N.V.','SA/AG','S.A.']
   for cs in clean suffix0:
       if cs in string:
          string = string[:string.rfind(cs[0])]
   #2.
   # 进行第二次后缀清理
   # 截取最后 5个字符,并删除其中的空格 为什么是5个(因为根据观察,自动清除的后缀里,最长
的是GROUP, 所以取最后5个判断不会有漏)
   str_suffix = string[:len(string)-6:-1][::-1].replace(' ','')
   clean_suffix = ['CO','ETF','AS','ADR','SA','AG','OLD','GROUP'] # 判断是否包含这些
后缀
   for cs in clean suffix:
       if cs in str suffix:
          string = string[:string.rfind(cs[0])]
   #3.
   #用basename进行第三次后缀处理
   string = cleanco.basename(string)
   return string
```

最后进行文件的保存:

```
Allcpdata_wb.save('All Company Data.xlsx')
```

数据处理结果如下:



第三步是 3. 对Customer name进行数据预处理

另外:

- 1. 相关的 Allcompany.xlsx 与 All Company Data.xlsx 文件都已上传至OneLive--liuchenxin文件夹
- 2. 方翔提出"识别customer name中是否含country" 的问题, 已向他建议pycountry中自带的模糊查询方法